



Aproximace funkcí, regrese

SEM2 – LS 2023/2024

Pavel Exner, Petr Rálek
NTI, FM TUL

pavel.exner@tul.cz, petr.ralek@tul.cz

Aproximace – lineární regrese I

Předpokládejme, že jsou dány dvojice čísel $(x_1, y_1), \dots, (x_n, y_n)$. Víme-li, že mezi veličinami x a y je lineární závislost, pak řešíme úlohu nalezení čísel $k, q \in \mathbb{R}$ tak, aby zadané dvojice čísel ležely co nejbližně přímky $y = kx + q$. V ideálním případě tedy k, q řeší soustavu

$$\begin{array}{l} y_1 = kx_1 + q \\ \vdots \\ y_n = kx_n + q, \end{array} \quad \text{neboli} \quad \begin{pmatrix} x_1 & 1 \\ \vdots & \vdots \\ x_n & 1 \end{pmatrix} \begin{pmatrix} k \\ q \end{pmatrix} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}$$

Máme však více rovnic (n) než neznámých (2). Můžeme se na problém dívat geometricky: Chceme, aby vzdálenost bodů $[x_i, y_i]$ od přímky $y = kx + q$ byla co nejmenší:

$$\arg \min S(k, q) = ?, \quad S(k, q) = \sum_{i=1}^n (kx_i + q - y_i)^2$$

Aproximace – lineární regrese II

Hledáme tedy minimum funkce $S(k, q)$:

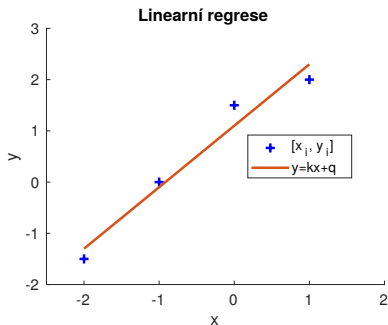
$$0 = \frac{\partial S}{\partial k} = 2 \sum_{i=1}^n (kx_i + q - y_i)x_i,$$

$$0 = \frac{\partial S}{\partial q} = 2 \sum_{i=1}^n (kx_i + q - y_i),$$

což nám dává soustavu 2 rovnic pro k, q :

$$k = \frac{n \sum x_i y_i - \sum x_i \sum y_i}{n \sum x_i^2 - (\sum x_i)^2}, \quad q = \frac{\sum x_i^2 \sum y_i - \sum x_i \sum x_i y_i}{n \sum x_i^2 - (\sum x_i)^2}.$$

Pozn: Minimalizace součtu druhých mocnin dává název Úloze nejmenších čtverců.



Úlohy nejmenších čtverců I

Označme soustavu $\mathbf{Ax} = \mathbf{b}$, kde $\mathbf{x} = [k, q]$ byl vektor hledaných parametrů přímky. Obecně takové soustavy nemají jednoznačné řešení.

Pro matici $\mathbf{A} \in \mathbb{R}^{n \times m}$ a pravou stranu $\mathbf{b} \in \mathbb{R}^n$ budeme hledat vektor $\mathbf{x} \in \mathbb{R}^m$ tak, aby

$$\mathbf{Ax} \approx \mathbf{b}$$

platilo v jistém smyslu.

Je-li $m < n$, pak má soustava více rovnic než neznámých a nazývá se **přeurčená**.

Pro takové soustavy často neexistuje žádné řešení. V případě, že $m > n$, říkáme, že soustava je **nedourčená**, a obvykle má nekonečně mnoho řešení.

Cílem metody nejmenších čtverců je nalézt vektor \mathbf{x} , který minimalizuje součet kvadrátů odchylek:

$$\sum_{i=1}^n (b_i - (\mathbf{Ax})_i)^2 = (\mathbf{b} - \mathbf{Ax}) \cdot (\mathbf{b} - \mathbf{Ax}) = \|\mathbf{b} - \mathbf{Ax}\|^2$$

Úlohy nejmenších čtverců II

$$\arg \min_{\mathbf{x}} (\mathbf{b} - \mathbf{Ax})^2 = ?$$

Nutná podmínka na minimum (nulová derivace podle \mathbf{x}) vede na soustavu rovnic

$$\mathbf{A}^\top (\mathbf{Ax} - \mathbf{b}) = \mathbf{0}.$$

Motivací pro úlohy nejmenších čtverců může být také jejich fyzikální význam. Pokud \mathbf{b} reprezentuje naměřená nebo jinak získaná data, pak téměř jistě tato data obsahují nějakou chybu. Cílem pak je nalézt co nejmenší změnu \mathbf{f} pravé strany (reprezentující chybu v datech) tak, aby \mathbf{x} bylo řešením soustavy

$$\mathbf{Ax} = \mathbf{b} + \mathbf{f}.$$

Požadavek minimalizovat normu $\|\mathbf{f}\|$ pak vede k definici následující úlohy.

Úlohy nejmenších čtverců III

Definition

Nechť $A \in \mathbb{R}^{n \times m}$ a $b \in \mathbb{R}^n$. Problém nejmenších čtverců (LS) je úloha nalézt $x \in \mathbb{R}^m$ takové, aby byla minimální

$$\|f\| \text{ za podmínky } Ax = b + f.$$

Zkratka LS pochází z anglického **least squares** — minimalizuje se zde euklidovská norma, tj. odmocnina ze součtu kvadrátů prvků rezidua $f = Ax - b$. Poznamenejme ještě, že lze také uvažovat tzv. **úplný problém nejmenších čtverců**, kde předpokládáme, že chyba je obsažena také v koeficientech matice A a hledáme tedy korekce E a f s minimálními normami tak, aby

$$(A + E)x = b + f.$$

Úlohy nejmenších čtverců IV

Pro řešení problému LS se často používá tzv. soustava normálních rovnic.

Věta

Nechť $\mathbf{A} \in \mathbb{R}^{n \times m}$ a $\mathbf{b} \in \mathbb{R}^n$. Pak $\mathbf{x} \in \mathbb{R}^m$ je řešení problému LS právě tehdy, když je řešením soustavy normálních rovnic

$$\mathbf{A}^\top \mathbf{A} \mathbf{x} = \mathbf{A}^\top \mathbf{b}.$$

Pozn.: Má-li \mathbf{A} plnou sloupcovou hodnost, pak je matice $\mathbf{A}^\top \mathbf{A}$ regulární a platí:

$$\mathbf{x} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b} = \mathbf{A}^\dagger \mathbf{b},$$

kde \mathbf{A}^\dagger je tzv. pseudoinverze \mathbf{A} . Vztah $\mathbf{x} = \mathbf{A}^\dagger \mathbf{b}$ má platnost i tehdy, když \mathbf{A} nemá plnou sloupcovou hodnost.

Pseudoinverze – příklad I

levá pseudoinverze ($m < n$):

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 1 & 1 \\ 1 & 3 \end{bmatrix}$$

$$\mathbf{A}^\top \mathbf{A} = \begin{bmatrix} 3 & 6 \\ 6 & 14 \end{bmatrix}$$

$$(\mathbf{A}^\top \mathbf{A})^{-1} = \begin{bmatrix} 2.\overline{3} & -1 \\ -1 & 0.5 \end{bmatrix}$$

$$(\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top = \begin{bmatrix} 0.\overline{3} & 1.\overline{3} & -0.\overline{6} \\ 0 & -0.5 & 0.5 \end{bmatrix} = \mathbf{A}^\dagger$$

$$\mathbf{A}^\dagger \mathbf{A} = \begin{bmatrix} 0.\overline{3} & 1.\overline{3} & -0.\overline{6} \\ 0 & -0.5 & 0.5 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 1 & 1 \\ 1 & 3 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I}, \quad \mathbf{A} \mathbf{A}^\dagger \neq \mathbf{I}$$

Pseudoinverze – příklad II

pravá pseudoinverze ($m > n$):

$$\mathbf{A} = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 5 & 7 & 7 & 9 \end{bmatrix}$$

$$\mathbf{A}\mathbf{A}^\top = \begin{bmatrix} 4 & 28 \\ 28 & 204 \end{bmatrix} \quad (\mathbf{A}\mathbf{A}^\top)^{-1} = \begin{bmatrix} 6.375 & -0.875 \\ -0.875 & 0.125 \end{bmatrix}$$

$$\mathbf{A}^\top (\mathbf{A}\mathbf{A}^\top)^{-1} = \begin{bmatrix} 2 & -0.25 \\ 0.25 & 0 \\ 0.25 & 0 \\ -1.5 & 0.25 \end{bmatrix} = \mathbf{A}^\dagger$$

$$\mathbf{A}\mathbf{A}^\dagger = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 5 & 7 & 7 & 9 \end{bmatrix} \begin{bmatrix} 2 & -0.25 \\ 0.25 & 0 \\ 0.25 & 0 \\ -1.5 & 0.25 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I}, \quad \mathbf{A}^\dagger \mathbf{A} \neq \mathbf{I}$$

Lineární regrese jako LS úloha I

Připomeňme úlohu lineární regrese s daty $[x_i, y_i]$ a regresní přímkou $y = kx + q$:

$$\begin{array}{l} y_1 = kx_1 + q \\ \vdots \\ y_n = kx_n + q, \end{array} \quad \text{neboli} \quad \begin{pmatrix} x_1 & 1 \\ \vdots & \vdots \\ x_n & 1 \end{pmatrix} \begin{pmatrix} k \\ q \end{pmatrix} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}.$$


Tuto **přeurčenou** soustavu lze řešit ve smyslu nejmenších čtverců, tj. pomocí soustavy normálních rovnic ve tvaru

$$\begin{pmatrix} \sum x_i^2 & \sum x_i \\ \sum x_i & n \end{pmatrix} \begin{pmatrix} k \\ q \end{pmatrix} = \begin{pmatrix} \sum x_i y_i \\ \sum y_i \end{pmatrix}$$

(ve všech sumách sčítáme přes $i = 1, \dots, n$).

Srovnejte se vztahy odvozenými dříve pomocí derivací.

Nelineární metoda nejmenších čtverců (NLS) I



Obrázek: Nelineární metoda nejmenších čtverců, $f(x, \beta_1, \beta_2) = |x + \beta_1|^{\beta_2}$.

Nelineární metoda nejmenších čtverců (NLS) II

Metoda LS předpokládá lineární vztah mezi daty $\{x_i\}$ a $\{y_i\}$. Toto omezení lze odstranit — hledáme pak obecně nelineární funkci $f(x, \beta)$, která má opět minimalizovat součet kvadrátů odchylek od zadaných dat:

$$\sum_{i=1}^n (y_i - f(x_i, \beta))^2.$$

Vektor β zde představuje neznámé parametry, na nichž funkce f může záviset komplikovaným (nelineárním) způsobem.

Nelineární metoda LS úlohu nalezení optimálního β převádí na iterační proces, při kterém se postupně zpřesňuje počáteční odhad vektoru.

Nelineární metoda nejmenších čtverců (NLS) III

V každém kroce tohoto procesu se funkce f nahradí funkcí, která na β závisí lineárně: Je-li dáno β , pak lze provést následující aproximaci:

$$f(x, \beta) \approx f(x, \bar{\beta}) + \sum_j \frac{\partial f}{\partial \beta_j}(x, \bar{\beta}) \cdot (\beta_j - \bar{\beta}_j),$$

kde výraz napravo od symbolu " \approx " je lineární vzhledem k prvkům vektoru β . Iterační proces pak můžeme definovat následovně:

- 1 Zvolíme β_0 .
- 2 Použijeme LS na linearizovanou funkci (s $\beta := \beta_0$).
- 3 Získáme tak nový vektor β_1 .
- 4 Opět použijeme LS, tentokrát na funkci linearizovanou v bodě $\beta := \beta_1$.
- 5 Opakujeme postup do té doby, než se β ustálí.

Nelineární metoda nejmenších čtverců (NLS) IV

Poznamenejme, že úspěšnost procesu závisí na tom, jak dobře bylo zvoleno β_0 . Pokud by totiž β_0 bylo příliš daleko od optimální hodnoty, může se stát, že cyklus nekonverguje.